Summary

Following Engineer's Degree Thesis, titled "Project and implementation of content

aware, file renaming tool" describes architecture project and implementation of Multifile

Renaming Utility software program.

Multifile Renaming Utility — MRU for short — is a tool which aims to allow the user

to rename many files based on metatdata contained therein.

This thesis is divided into six chapters containing theoretical and practical description

of the problem and its solutions.

First chapter contains introdution to the project and motivation which led to its creation.

Second chapter describes theoretical fundaments of described problem and terminology

used in the work.

Third chapter is a review of few existing applications that aim to solve described problem.

Fourth section introduces work environment in which application were developed.

Fifth chapter contains architecture description as well as implementation details of the

finished application.

The last, sixth chapter consists of the conclusions made during project development.

**Keywords:** filesystem, plugins, metadata, wxWidgets, boost, SigC++, C++

4

Streszczenie

Niniejsza praca inżynierska na temat "Projekt i implementacja narzędzia do masowej

refaktoryzacji identyfikatorów plików z uwzględnieniem ich zawartości" opisuje projekt

architektury oraz implementacje programu Multifile Renaming Utility.

Multifile Renaming Utility — w skrócie MRU — jest programem narzędziowym

mającym na celu umożliwienie automatycznej zmiany nazw wielu plikom ze względu na

metadane w nich zawarte.

Praca jest podzielona na sześć rozdziałów zawierających teoretyczny jak i praktyczny

opis problemu i jego rozwiązania.

Pierwszy rozdział zawiera wstępny opis projektu i motywacje do jego utworzenia.

Drugi rozdział zawiera teoretyczne podstawy problemu oraz opisuje terminologię użytą

w pracy.

Trzeci rozdział przedstawia przykłady istniejących aplikacji wraz z ich subiektywną oceną

pod względem skuteczności w stosunku do przedstawionego problemu.

Czwarty rozdział opisuje środowisko pracy, które zostało wykorzystane do stworzenia

implementacji.

Piąty rozdział zawiera opis architektury, a także szczegóły implementacji aplikacji.

Ostatni, szósty rozdział składa się z wniosków na temat wykonanego projektu.

Słowa kluczowe: system plików, wtyczki, metadane, wxWidgets, boost, SigC++, C++

5

# Spis treści

Spis treści			5
1	$\mathbf{Wstep}$		8
	1.1	Motywacja	8
	1.2	Cel i zakres pracy	9
	1.3	Założenia	10
	1.4	Plan pracy	10
2	Teoria		11
	2.1	Dane w systemie komputerowym	11
	2.2	Systemy plików i identyfikacja danych	12
		2.2.1 Katalogi i ścieżki do plików	13
		2.2.2 Różnice w identyfikacji plików wśród różnych systemów operacyjnych	13
	2.3	Metadane	15
3	Przegląd istniejących rozwiązań		16
	3.1	Bulk Rename Utility	16
	3.2	Métamorphose	17
	3.3	KRename	18
	3.4	Inne rozwiązania	19
4	Śro	dowisko pracy	21
	<i>4</i> 1	Jezyk C++	21

		4.1.1 LLVM Clang	21	
	4.2	System operacyjny FreeBSD	22	
	4.3	Mercurial	22	
	4.4	CMake	23	
	4.5	Vim	23	
5	Imp	lomontogio	24	
J	-	olementacja 24		
	5.1	Specyfikacja wymagań	24	
		5.1.1 Wymagania funkcjonalne	24	
		5.1.2 Wymagania niefunkcjonalne	24	
	5.2	Wykorzystane biblioteki	25	
		5.2.1 SigC++	25	
		5.2.2 boost::filesystem	25	
		5.2.3 wxWidgets	26	
		5.2.4 ICU	26	
		5.2.5 CppUnit	26	
		5.2.6 TagLib	26	
	5.3	Rdzeń aplikacji - klasa MruCore	27	
	5.4	glue_cast - łącznik technologii	27	
	5.5	Wyrażenia zawierające metatagi	29	
	5.6	System modułów	33	
	5.7	Typy modułów w MRU	34	
	5.8	Moduły UI	34	
		5.8.1 wxWidgetsUi	35	
	5.9	InputPlugin	36	
		5.9.1 Dekoratory iteratora	36	
	5.10	Moduł OutputPlugin — BoostOutput	37	
	5.11	Moduły metatagów	37	
		5 11 1 Count	27	

	5.11.2 Audio	38		
	5.11.3 Name	38		
	5.11.4 Ext	39		
	5.11.5 Dir	39		
	5.11.6 TextCase	39		
	5.12 Testy	40		
	5.13 Możliwości rozwoju i ponownego wykorzystania komponentów	41		
6	Wnioski	44		
Sp	Spis rysunków			
	Spis rysunków	46		
Sp	pis tablic	47		
	Spis tabel	47		
Bi	bliografia	48		

## Rozdział 1.

## Wstęp

Z każdym rokiem ludzie oraz komputery generują coraz większą ilość informacji. Mimo że duża część z nich jest przechowywana w dobrze strukturyzowanych bazach danych, to ciągle, większość ludzi ma bezpośredni dostęp jedynie to tego co przechowuje w systemie plików własnego komputera.

Od dziesięcioleci dyski twarde pozostają głównym kontenerem danych dla komputerów na całym świecie. Wiele użytkowników komputera na przestrzeni lat tworzy swoistego rodzaju kolekcje danych — albumy zdjęć, biblioteki muzyczne czy filmowe, a także duże ilości dokumentów na potrzeby działalności gospodarczej czy też prywatnej, które stopniowo zastępują starsze formy gromadzenia informacji. Dodatkowo, niektórzy administratorzy zarządzający serwerami aplikacji zmagają się z problemem wielkiej ilości plików generowanych przez użytkowników ich systemów.

## 1.1 Motywacja

Tysiące plików mogą stworzyć gąszcz informacyjny w którym człowiek będzie czuł się zagubiony. Przy coraz większej ilości informacji nie bez znaczenia pozostaje czynnik ludzki którego możliwości percepcji są ograniczone. Istnieje wiele programów ułatwiających katalogowanie danych jednak skierowane są one często na pojedyncze typy plików, a także wymagają od użytkownika przyzwyczajenia się do ich używania.

Z drugiej strony, przeciętny użytkownik jest zwykle przyzwyczajony do standardowego programu oferowanego przez większość systemów operacyjnych — przeglądarki plików.

Problemem jednak jest fakt że programy rzadko generują przyjazne użytkownikowi nazwy plików, zwykle ograniczając się do prostego prefiksu i grupy kolejnych numerów zapewniających unikalność. Doświadczyły tego na pewno osoby przenoszące dane z kamer cyfrowych, w których po każdym usunięciu danych z pamięci urządzenia, kolejne zdjęcia numerowane są od początku. Może doprowadzić to do konfliktu przy kopiowaniu wielu sesji do tego samego katalogu na dysku lub nawet nadpisaniu starszych obrazów.

Najprostszym rozwiązaniem z punktu widzenia programisty możne być zrzucenie obowiązku wyboru nazwy na samego użytkownika, jednak rzadko jest to dobrym rozwiązaniem gdyż w dzisiejszym świecie liczy się szybkość działania, a zmuszanie użytkownika do myślenia nigdy nie przyspiesza jego działań.

## 1.2 Cel i zakres pracy

Celem niniejszej pracy inżynierskiej jest stworzenie programu narzędziowego pozwalającego na automatyczne generowanie identyfikatorów plików na podstawie metadanych w nich zawartych, a także ich stosowanie do zbiorów plików wybranych przez użytkownika.

Zakres pracy obejmuje:

- Przegląd istniejących rozwiązań programów i technik wspomagających masową zmianę identyfikatorów plików.
- Porównanie funkcjonalności istniejących narzędzi i ich ograniczeń.
- Projekt oraz implementacja wieloplatformowej architektury modułów.
- Stworzenie parsera wyrażeń zawierających metatagi.
- Projekt graficznego interfejsu użytkownika opartego na bibliotece wxWidgets.
- Implementacja przykładowych modułów metatagów.

• Testy aplikacji.

#### 1.3 Założenia

Gotowa aplikacja powinna być niezależna od systemu operacyjnego w stopniu w jakim pozwalają na to zależności użytych bibliotek. Dzięki modułowej budowie powinna także udostępniać interfejs pozwalający na jej łatwą rozbudowę bez ingerencji w istniejący kod źródłowy.

## 1.4 Plan pracy

W rozdziałe 2 opisano teoretyczny schemat przechowywania danych oraz genezę systemów oraz identyfikacji plików. Rozdział ?? zawiera opis środowiska wykorzystanego do stworzenia projektu i implementacji aplikacji. Rozdział 5 zawiera szczegółowy opis architektury aplikacji wraz z rozwiązaniami wykorzystanymi do jej stworzenia. Ostatni rozdział — 6 — zawiera wnioski na temat wykonanego projektu.

## Rozdział 2.

## Teoria

W niniejszym rozdziale postaram się przybliżyć problem identyfikatorów plików opisując środowisko w którym występuje.

## 2.1 Dane w systemie komputerowym

Jednym z podstawowych elementów systemu komputerowego jest jego pamięć. Od początku istnienia komputerów istniała potrzeba składowania danych wymaganych przy praktycznie każdych operacjach wykonywanych przez jednostkę centralną komputera. Jako że pierwsze systemy komputerowe były wykorzystywane do obliczeń typowo matematycznych, algorytmy na nich uruchamiane nie wymagały wielkich kontenerów na dane. W tych czasach wbudowane rejestry oraz ulotna pamięć RAM zaspokajały potrzemy rynku. Jednak wraz z rozwojem sprzętu i algorytmów na nim uruchamianych pojawiła się potrzeba przechowywania coraz to większej ilości danych jak, a także (dzięki zastosowaniu architektury von Neumanna) samych programów. Pojawiła się idea nieulotnej oraz bardziej pojemnej pamięci — dysku twardego.

Pojemności pierwszych dysków twardych stanowiły promil dzisiejszych jednostek toteż nie wymagały stosowania systemów plików — były po prostu nieulotnym rozszerzeniem pamięci operacyjnej RAM. Jednak wraz ze zwiększeniem ich pojemności oraz generalizacją

oprogramowania, pojawiła się potrzeba standaryzowania i kategoryzacji przechowywanych na dyskach danych, która spowodowała powstanie systemów plików.

#### 2.2 Systemy plików i identyfikacja danych

System plików stanowi warstwę abstrakcji między programami, a danymi zapisanymi na nośniku — dysku twardym, karcie pamięci czy też płycie CD. System plików jest metodą zapisu danych, schematem dzięki któremu programy nie muszą operować na surowych blokach bajtów lecz mogą korzystać z bardziej wysokopoziomowych deskryptorów plików, węzłów bądź ścieżek dostępu.

Zwykle systemem plików zarządza system operacyjny, który to udostępnia odpowiedni API<sup>1</sup>, a także kontroluje dostęp do danych ze względu na uprawnienia użytkownika, programu lub samego zasobu będacego podmiotem zapytania programu.

Istnieje wiele typów oraz implementacji systemów plików, które można podzielić na dwie kategorie:

- tradycyjne znajdujące zastosowanie przy przechowywaniu dowolnych (ogólnych) danych w postaci plików
- specjalne dostosowane do specyficznych rozwiązań (jak na przykład bazy danych)

Oddzielną kategorię mogą stanowić zdobywające coraz większą popularność wirtualne systemy plików — różnią się one od tradycyjnych i specjalistycznych tym że nie przechowują danych fizycznie na nośniku, a są raczej aplikacjami udostępniającymi (generującymi) struktury danych na żądanie programu. Przykładem takich systemów mogą być: procfs — udostępniający dostęp do procesów systemowych i ich atrybutów w systemach rodzin GNU/Linux oraz BSD, czy też NFS (Network File System) — pozwalający na dostęp do systemów plików znajdujących się na innych komputerach w sieci[7].

<sup>&</sup>lt;sup>1</sup>API — Application Programming Interface

#### 2.2.1 Katalogi i ścieżki do plików

Niniejsza praca skupia się na problemie opisywania danych w tradycyjnych systemach plików za pomocą tak zwanych ścieżek, które identyfikują zasób w drzewie katalogów [6].

Tradycyjne systemy plików pozwalają na przechowywanie danych w drzewiastej strukturze danych zwanej drzewem katalogów. W większości implementacji każdy węzeł takiego drzewa może być katalogiem albo plikiem albo dowiązaniem do innego węzła. Dodatkowo węzły katalogów jako jedyne mogę posiadać węzły podległe — podkatalogi[7]. Każdy węzeł (prócz węzła-korzenia) jest identyfikowany przez unikalny względem węzła-rodzica identyfikator zwany nazwą pliku.

Lista kolejnych nazw odseparowanych przez umowny symbol stanowi ścieżkę do pliku. Ścieżki mogą być rozwijane względem aktualnej pozycji w drzewie katalogów bądź od jego korzenia, odpowiednio nazywa się je ścieżkami względnymi oraz bezwzględnymi. Warto zauważyć iż struktura drzewa katalogów nie wymusza sposobu rozkładu danych w systemie plików — tak długo jak identyfikatory pozostają unikalne, pliki przez nie opisywane mogą znajdować się w tym samym katalogu².

# 2.2.2 Różnice w identyfikacji plików wśród różnych systemów operacyjnych

Format ścieżki do pliku narzucany jest niezależnie od zastosowanego systemu plików przez system operacyjny.

Systemy kompatybilne ze standardem POSIX, takie jak Apple MacOS, rodzina BSD, a także rodzina GNU/Linux używają drzew katalogów z pojedynczym, nienazwanym korzeniem oznaczanym symbolem prawego ukośnika (slash) — '/' [8].

Symbol prawego ukośnika jest również używany jako separator elementów (poziomów) ścieżki i nie może stanowić elementu identyfikatora węzła w wymienionych środowiskach. Przykład ścieżki zgodnej ze standardem POSIX:

 $<sup>^2\</sup>mathrm{W}$  praktyce ilość plików które mogą należeć do jednego węzła zależy od implementacji.

#### /home/idlecode/projects/mru/doc/main.tex

Systemy operacyjne z rodziny Windows korporacji Microsoft<sup>3</sup> wykorzystują natomiast lewy ukośnik (backslash) — '\' — jako separator komponentów ścieżki oraz uniemożliwiają stosowanie większej ilości symboli w nazwach.

Drzewo katalogów systemu Windows może posiadać kilka korzeni (po jednym dla każdego dysku/partycji) oznaczanych pojedynczymi, zwykle dużymi literami alfabetu łacińskiego. Litera dysku wraz z symbolem dwukropka poprzedza właściwą ścieżkę do pliku:

#### C:\Users\idlecode\My Documents\Projects\MRU\doc\main.tex

Dodatkowo w przypadku obu<sup>4</sup> wyżej wymienionych schematów, nazwy elementów nie mogą zawierać znaku zerowego (NUL — o kodzie heksadecymalnym 0x00), który może zostać zinterpretowany jako koniec łańcucha znaków[5].

Większość implementacji pozwala zawrzeć pełen zakres symboli (znaków) w ścieżce za pomocą kodowań z rodziny UTF przy czym pojedynczy identyfikator może mieć maksymalną długość 255 bajtów[6]. Warto tu zauważyć iż systemy z rodziny Windows zachowują wielkość liter w identyfikatorach lecz przy interpretacji ścieżek — rozwijaniu ich do odpowiadających węzłów — nie gra ona znaczenia. Takie zachowanie nie występuje w systemach kompatybilnych ze standardem POSIX. Istnieje również możliwość stosowania ukośników prawych do rozdzielania komponentów ścieżki tak jak to ma miejsce w systemach POSIX-owych.

Istnieje jeszcze kilka schematów zapisu ścieżek, które nie zostały przybliżone ze względu na zakres niniejszej pracy.

<sup>&</sup>lt;sup>3</sup>Istnieje więcej systemów operacyjnych używających podobnego schematu

 $<sup>^4\</sup>mathrm{System}$  MacOS nie posiada tego ograniczenia

#### 2.3 Metadane

Metadane z definicji są danymi opisującymi inne dane. Metadane stosowane są w przypadkach gdy nie istnieje fizyczna możliwość dołączenia lub dodatkowe informacje są zbyt luźno powiązane z opisywanymi danymi. Przykładem metadanych mogą być karty biblioteczne — informują one o statusie i historii książki nie będąc jej integralną częścią.

W systemach plików, metadane dostarczają informacji o plikach zapisanych w drzewie katalogów. Przykładem komputerowych metadanych może być wspominana wcześniej nazwa czy ścieżka do pliku, która nie jest jego integralną częścią — może zostać zmieniona bez naruszania struktury przechowywanego dokumentu. Dodatkowo systemy plików często dostarczają ogólnych (wspólnych dla każdego pliku) atrybutów takich jak jego rozmiar, czas utworzenia lub ostatniej modyfikacji czy też prawa dostępu.

Ciekawym przykładem metadanych są rozszerzenia nazw plików — sufiksy rozpoczynające się od ostatniego znaku kropki w nazwie. Rozszerzenia odgrywały ważną rolę w systemach operacyjnych korporacji Microsoft gdzie stanowiły integralną część nazwy i pozwalały systemowi skojarzyć typ pliku z programem go obsługującym. W systemach POSIX-owych informacja o typie pliku jest zwykle przekazywana wraz z kontekstem uruchomienia aplikacji operującej na pliku toteż rozszerzenia (jeśli już są fragmentem nazwy) stanowią bardziej informacje dla użytkownika.

Niektóre formaty plików (szczególnie kontenery multimediów) pozwalają na integracje metadanych z samym plikiem. Jako że pliki (zwłaszcza binarne) mogą stosować dowolną strukturę zapisu, nie istnieje ogólny algorytm wyciągnięcia zawartych w ten sposób informacji.

Do metadanych można zaliczyć także dane generowane, takie jak sumy kontrolne, które są wartościami liczonymi na podstawie zawartości samego pliku. Sumy kontrolne używane mogą być w celu testów integralności lub identyczności.

## Rozdział 3.

## Przegląd istniejących rozwiązań

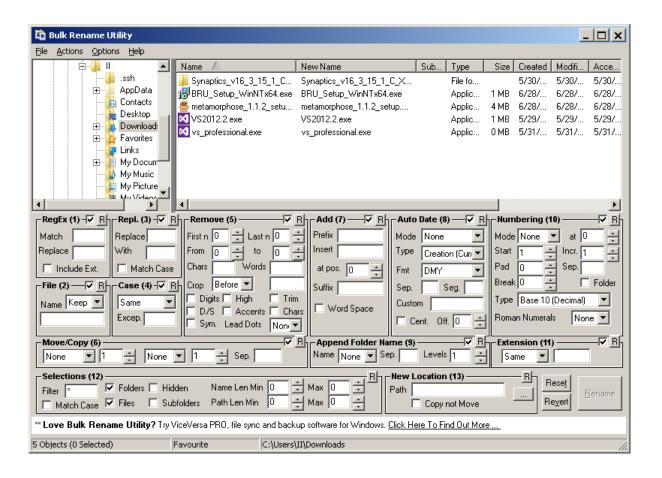
Jako że problem zmiany identyfikatorów plików znany już jest od lat, powstało wiele programów próbujących się z nim uporać. Wiele z istniejących rozwiązań zostało zaprojektowanych dla plików konkretnego typu lub są modułami większych aplikacji lecz istnieje kilka<sup>1</sup> implementacji przeznaczonych do ogólnego zastosowania.

Poniżej zostały przedstawione trzy wybrane implementacje wraz z subiektywną opinią na ich temat.

## 3.1 Bulk Rename Utility

Jednym z bardziej zaawansowanych i polecanych programów na platformę Microsoft Windows jest Bulk Rename Utility. Aplikacja umożliwia ekstrakcje metadanych z plików audio (zawartych w tagach ID3v1) i obrazów zawierających dane EXIF. Posiada ona także wiele funkcjonalności związanych z modyfikacją istniejącej nazwy — takich jak zastępowanie z użyciem wyrażeń regularnych. Program wyróżnia się wsparciem dla modyfikacji nazw i atrybutów katalogów, a także zwartym interfejsem. Narzędzie to nie wspiera jednak zmiany kolejności wykonywania działań na nazwie — wszystkie operacje posiadają stałą pozycje w kolejce wywołania i istnieje jedynie możliwość ich włączenia

<sup>&</sup>lt;sup>1</sup>Aplikacje zostały wybrane ze względu na ich popularność i podejście do rozwiązania problemu



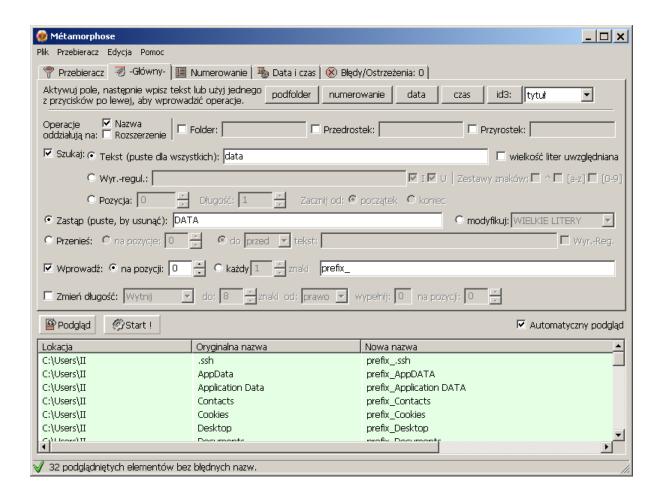
Rysunek 3.1: Okno główne programu Bulk Rename Utility

lub wyłączenia.

Bulk Rename Utility posiada również odpowiednik bez interfejsu graficznego — Bulk Rename Command — który jest oddzielnym programem udostępniającym funkcjonalność programu z linii poleceń (co może znaleźć zastosowanie w skryptach powłoki).

## 3.2 Métamorphose

*Métamorphose* podobnie jak *Bulk Rename Utility* korzysta z wbudowanego zestawu funkcjonalności jednak posiada pewne wsparcie dla szablonów nazw plików. Jest również aplikacją wieloplatformową, a także dzięki zastosowaniu zakładek — bardziej przejrzystą.



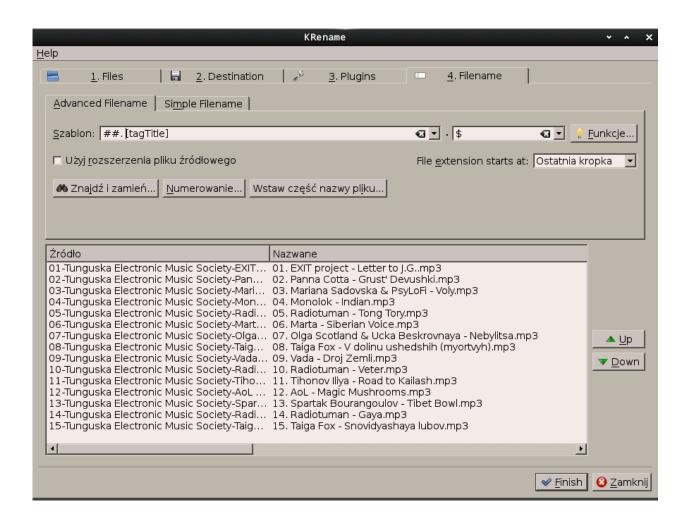
Rysunek 3.2: Jedna z zakładek programu Métamorphose

#### 3.3 KRename

KRename w odróżnieniu od poprzednich programów nie posiada wersji dla systemów Windows. Zestaw zakładek pozwala na znalezienie plików, wybranie akcji do wykonania, a także przegląd i edycję wtyczek umożliwiających ekstrakcje danych.

Poza trybem edycji szablonu dla nazw plików istnieje prostszy interfejs pozwalający na podstawowe operacje dodania sufiksu lub prefiksu, a także zmianę wielkości znaków w nazwie.

Zaletą programu jest duży wybór wtyczek pozwalających także na modyfikacje metadanych a nawet zawarcie w nowej nazwie rezultatu wywołania kodu JavaScript.



Rysunek 3.3: Konfiguracja szablonu nazwy pliku w KRename

#### 3.4 Inne rozwiązania

Osoby korzystające z systemów POSIX-owych posiadają ciekawą alternatywę dla jakichkolwiek specjalizowanych aplikacji — tekstową powłokę zwaną shellem.

Nowoczesne powłoki shell takie jak zsh czy bash posiadają funkcjonalności umożliwiające łączenie wyników wywołań wielu komend co wraz z bogatą liczbą programów dostępnych dla wspomnianych systemów, umożliwia stworzenie polecenia które mogłoby w prosty sposób modyfikować identyfikatory plików.

Listing 3.1Polecenie powłoki zmieniające roszerzenia plików JPEG find ./ –name "\*.JPG" –exec rename –v 's/\.JPG/\.jpg/'  $\{\}$ \;

Na listingu 3.1 zostało pokazane przykładowe polecenie powłoki zamieniające rozszerzenia plików JPEG z 'JPG' na 'jpg'. Wykorzystuje ono dwa programy:

- find znajduje pliki o rozszerzeniu kończącym się na '.JPG' (przez zastosowanie parametru -name "\*.JPG")
- rename dokonuje faktycznej zmiany nazwy dla pojedynczego pliku

Polecenia realizujące proste zmiany nazw mogą zostać napisane przez średnio-zaawansowanego użytkownika powłoki jednak aby otrzymać bardziej złożone modyfikacje wymagane jest użycie wielu programów co nie jest tak trywialne jak wyżej wymieniony przykład.

## Rozdział 4.

## Środowisko pracy

## 4.1 Język C++

Aplikacja MRU została napisana przy użyciu języka C++ w standardzie z roku 2003 (ISO/IEC 14882:2003). Język C++ jest dojrzałym, wieloplatformowym językiem programowania średniego poziomu, używanym od wielu lat przez programistów na całym świecie do tworzenia programów użytkowych, gier, sterowników czy nawet systemów operacyjnych. Dzięki kompatybilności z  $C^1$  pozwala na wykorzystanie wielu istniejących bibliotek napisanych zarówno w C jak i C++[1].

#### 4.1.1 LLVM Clang

LLVM — Low Level Virtual Machine — jest modułową architekturą do budowy kompilatorów. Pozwala ona na oddzielenie parserów różnych języków programowania od modułu optymalizacji (wspólnych dla wszystkich języków kompilowalnych) i emiterów kodu bajtowego dla różnych platform.

<sup>1</sup>C++ nie jest całkowicie kompatybilny z C, jednak różnice w obu tych językach są na tyle małe że rzadko wpływają negatywnie na kompatybilność (szczególnie na poziomie ABI).

Clang jest parserem² języków C i C++ dla architektury LLVM. Projekt jest otwarty (wydawany na licencji BSD) i zdobywa coraz większą popularność³ dorównując, a nawet przewyższając w niektórych testach GCC⁴.

## 4.2 System operacyjny FreeBSD

System FreeBSD jest darmowym i otwartym systemem operacyjnym z rodziny BSD wywodzącej się z rodziny UNIX-ów. Podobnie do dystrybucji GNU/Linux, sam w sobie wraz z wieloma, otwartymi bibliotekami tworzonymi przez społeczność stanowi środowisko przyjazne programistom.

#### 4.3 Mercurial

Do zarządzania plikami źródłowymi oraz kopią zapasową został wykorzystany rozproszony system kontroli wersji Mercurial wraz z serwisem bitbucket.org. Narzędzie to pozwala na synchronizację kodów źródłowych między wieloma maszynami, ułatwiając tym samym pracę nad pojedynczym projektem wielu programistów.

W odróżnieniu od scentralizowanych systemów kontroli wersji takich jak SVN, Mercurial nie wymaga pojedynczego serwera, ani serwera w ogóle. Pełne repozytorium może być trzymane na każdej maszynie z której korzysta programista, a praca różnych programistów może być synchronizowana bezpośrednio między nimi samymi[3].



Rysunek 4.1: Logo systemu Mercurial

 $<sup>^2</sup>$ Clang jest określany jako 'frontend' lecz słowo to nie ma dobrego odpowiednika w języku polskim, a główną funkcjonalnością tego narzędzia jest właśnie parsowanie plików źródłowych z kodem C lub C++ do kodu pośredniego LLVM

 $<sup>^3{\</sup>rm Od}$ listopada 2012 Clang wraz z LLVM stał się domyślnym kompilatorem dla systemu FreeBSD  $^4{\rm GNU}$  Compiler Collection

#### 4.4 CMake

Aby projekt był jak najbardziej przenośny i niezależny od platformy, ważne jest aby jego proces budowania również taki był. W celu zapewnienia łatwego wsparcia dla budowania projektu na wielu platformach i wielu łańcuchach narzędziowych, do budowania MRU został zastosowany CMake — narzędzie do zarządzania procesem kompilacji i zależnościami.



Rysunek 4.2: Logo narzędzia CMake

CMake pozwala programiście określić z jakich elementów składa się program i jakich zewnętrznych zasobów (bibliotek) wymaga. Narzędzie następnie interpretuje skryptowy plik konfiguracyjny i tworzy natywne dla danej platformy pliki projektowe zawierające odpowiednią do zbudowania projektu konfigurację.

#### 4.5 Vim

Edytor Vim jest rozszerzoną wersją klasycznego edytora vi, który jest standardowym oprogramowaniem w przypadku dystrybucji zarówno GNU/Linux jak i systemów z rodziny BSD. Vim jest też platformą dla wielu pluginów które tworzą jego faktyczną funkcjonalność. Edytor sam w sobie wspiera pracę z wieloma dokumentami, koloruję składnie plików źródłowych i posiada wiele komend ułatwiających produkcję kodu. Dzięki wtyczkom istnieje możliwość rozszerzenia go o zaawansowane



Rysunek 4.3: Logo edytora Vim

kompletowanie składni czy także szybkie wstawki kodu (ang. snippety).

## Rozdział 5.

## Implementacja

## 5.1 Specyfikacja wymagań

#### 5.1.1 Wymagania funkcjonalne

Użytkownikiem aplikacji jest administrator lub osoba posiadająca dużą kolekcję plików. Wymagane funkcjonalności:

- Możliwość wyboru katalogu zawierających pliki wymagające zmiany nazw
- Udostępnienie filtrów glob pozwalających na automatyczną selekcję plików
- Możliwość ekstrakcji metadanych z plików audio (MP3)
- Wybór operacji na samych plikach lub pełnych ścieżkach (wraz z katalogami)
- Automatyczna iteracja względem wybranych plików i zmiana ich nazwy
- Notyfikacja o błędach ekstrakcji metadanych

#### 5.1.2 Wymagania niefunkcjonalne

• Minimalistyczny, skalowalny interfejs użytkownika

 Aplikacja powinna być przenośna na poziomie kodu źródłowego między platformami zgodnymi ze standardem POSIX.

## 5.2 Wykorzystane biblioteki

#### 5.2.1 SigC++

SigC++ jest biblioteka dla języka C++implementującą bezpieczny (ze względu na typy) mechanizm sygnałów. Sygnały (zdarzenia) są wysokopoziomowym odpowiednikiem wywołań zwrotnych używanych do wstrzykiwania istniejącej programisty-użytkownika kodu do W językach niskopoziomowych, implementacji. takich jak C często stosuje się do tego celu wskaźniki



Rysunek 5.1: Logo biblioteki SigC++

do funkcji, jednak ich niskopoziomowa natura może powodować trudne do wykrycia błędy spowodowane przekazaniem złego typu wskaźnika lub błędnej jego sygnatury. Biblioteka udostępnia wysokopoziomowe szablony obiektów sygnałów jak i interfejsy do zastosowania w klasach użytkownika, ułatwiające w znaczny sposób zarządzanie podpiętymi zdarzeniami.

SigC++ jest często używana w projektach GUI takich jak pulpit GNOME; w takim też celu zostanie ona użyta w aplikacji MRU.

#### 5.2.2 boost::filesystem

Biblioteka boost::filesystem pozwala na niezależny od systemu operacyjnego dostęp do drzewa katalogów[4]. Ze względu na swoją uniwersalność została użyta w modułach BoostInput oraz BoostOutput, które są domyślnymi sterownikami wejścia/wyjścia w aplikacji MRU.

#### 5.2.3 wxWidgets

wxWidgets jest wieloplatformową biblioteką do tworzenia graficznych interfejsów użytkownika (ang. GUI). W projekcie została wykorzystana do stworzenia wtyczki interfejsu (ui module) wxWidgetsUi. wxWidgets udostępnia i pozwala tworzyć przenośny zestaw klas kontrolek, które są tłumaczone na natywne kontrolki środowiska uruchamiającego



Rysunek 5.2: Logo biblioteki wxWidgets

#### 5.2.4 ICU

aplikacje.

ICU — International Components for Unicode— jest biblioteką opracowaną przez IBM wspierającą lokalizacje, globalizacje i umożliwiającą operacje na łańcuchach znaków w kodowaniach UTF.

Jako że główne operacje w aplikacji MRU przeprowadzane są na łańcuchach znaków, istotne jest aby wykonywane były one z należytą precyzją. ICU jest najbardziej zaawansowaną, ogólnie dostępną biblioteką tego typu z długą historią zastosowań.

#### 5.2.5 CppUnit

Aby zapewnić najwyższą jakość produkowanego kodu i zmniejszyć ryzyko błędów (w tym opartych na regresji), większość z modułów i interfejsów aplikacji została zaprojektowana i zaimplementowana z użyciem testów jednostkowych. Testy zostały napisane w oparciu o bibliotekę CppUnit, która ułatwia ich uruchamianie, debugowanie i zarządzanie nimi.

#### 5.2.6 TagLib

TagLib jest biblioteką pozwalającą na ekstrakcje metadanych z wielu typów plików multimedialnych. W MRU została użyta w implementacji metatagu Audio umożliwiającego

dostęp do informacji o tytule, roku wydania, a także wykonawcy i albumie do którego należy utwór muzyczny.

#### 5.3 Rdzeń aplikacji - klasa MruCore

Rdzeniem aplikacji jest klasa MruCore stanowi ona interfejs do całej funkcjonalności programu i udostępnia informacje o jego działaniu.

Klasa MruCore zawiera metody umożliwiające wtyczkom UI na kontrolę pracy programu bez implementacji powtarzalnej logiki, a sygnały zdefiniowane w klasie dostarczają informacji zwrotnej o pracy aplikacji.

## 5.4 glue cast - łącznik technologii

Jako że w aplikacji zostały wykorzystane różne biblioteki, wprowadziły one wiele wymagań co do obsługiwanych typów danych. Biblioteka ICU korzysta głównie z klas takich jak UnicodeString podczas gdy biblioteki boost zostały oparte na strukturach ze standardowej biblioteki STL takich jak std::string. Do tego dochodzi niskopoziomowa warstwa API systemu operacyjnego która często operuje na surowych łańcuchach znaków — const char \*.

Aby ułatwić konwersję między różnymi redundantnymi typami danych, został opracowany szablon glue\_cast podobny w zastosowaniu do wbudowanych w język język rzutowań takich jak dynamic\_cast czy reinterpret\_cast.

Listing 5.1glue.hpp

```
template < typename DstType, typename SrcType > inline
DstType
glue_cast(const SrcType &a_value)
{
   return DstType(a_value);
}
```

Przedstawiona powyżej generyczna implementacja szablonu często jest niewystarczająca lecz dzięki odpowiednim specjalizacjom, w całym programie można wykorzystywać jednorodną składnie odpowiadającą za rzutowania.

Listing 5.2Fragment glue\_impl.hpp — specjalizacja dla std::wstring i wxString

template > inline

wxString
glue\_cast < wxString , std::wstring > (const std::wstring &a\_value)

{
 return wxString(a\_value.c\_str(), wxConvUTF8);
}

template > inline

std::wstring
glue\_cast < std::wstring , wxString > (const wxString &a\_value)

{

Dzięki wykorzystaniu szablonów nie ma potrzeby tworzenia nowych funkcji konwersji, a całość wygląda bardziej spójnie, a także jest łatwiejsza w utrzymaniu (powtarzający się kod został zamknięty w specjalizacjach). Dodatkowym atutem użytego rozwiązania jest jego uniwersalność — wybrane specjalizacje można wykorzystać w jakimkolwiek projekcie używających specjalizowanych typów. Dodawanie nowych konwersji sprowadza się do dopisania kolejnej pary szablonów.

return std::wstring(a\_value.wc\_str());

}

#### 5.5 Wyrażenia zawierające metatagi

Najważniejszym elementem projektu MRU są metatagi wraz metawyrażeniami na które się składają. Metawyrażenia używane są jak wzorzec (szablon) na podstawie którego generowane są kolejne nazwy plików.

Za każdym razem gdy MRU zmienia plik na którym operuje, metawyrażenie jest ewaluowane. Każde wystąpienie tagu jest przekładane na wywołanie odpowiedniej metody na obiekcie wtyczki, a rezultat tego wywołania jest wstawiany w miejsce wystąpienia tagu. Metatagi są reprezentacjami wywołań do odpowiadającym im wtyczek.

Metatag jest identyfikatorem wprowadzonym do zwykłego tekstu, składającym się z czterech elementów które nie mogą zostać rozdzielone białymi znakami. Metatag rozpoczyna się od symbolu procent — '%' — po którym następuje nazwa metatagu składająca się ze znaków alfanumerycznych alfabetu łacińskiego¹. Po nazwie następuje para nawiasów

```
%Replace("", "_"){wyrażenie}
```

Rysunek 5.3: Metatag z wyróżnionymi elemetami na niego się składającymi

— '(' wraz z ')' — zawierających opcjonalnie listę parametrów inicjalizacyjnych metatag. Nie istnieją ograniczenia co do zawartości listy inizjalizującej — może ona zawierać pełen zakres znaków. Ostatnim elementem jest opcjonalny zakres działania metatagu — jest to obszar zawierający się między parą nawiasów klamrowych ('{' oraz '}') który sam w sobie jest metawyrażeniem. Dzięki temu, efekty metatagów mogą się na siebie nakładać.

Rysunek 5.4: Przykładowe metawyrażenie wraz z wyróżnionymi elementami metatagów

 $<sup>^1\</sup>mathrm{Z}$ technicznego punktu widzenia nic nie stoi na przeszkodzie aby do zapisu nazwy metataga zastosować pełen zestaw znaków, lecz ze względu na globalizacje nie wszyscy użytkownicy potrafili by używać każdej nazwy.


Parsowanie metawyrażenia rozpoczyna się od tokenizacji. Tekst wejściowy rozdzielany na grupy które mogą składać się z pojedynczych symboli (użytych w metatagu) bądź łańcucha znaków niezawierającego w/w symboli.

Następnym krokiem jest przekazanie listy powstałej przy tokenizacji do leksera, który przypisuje umowne symbole dla konkretnych jej elementów tworząc tym samym listę tokenów. Na tym etapie każdy token zawiera tekst (bądź pojedynczy symbol) z którego powstał, typ i pozycję w oryginalnym tekście wejściowym.

Ostatnim etapem jest interpretacja listy tokenów przez parser generujący obiekty metawyrażeń (gotowe do wykonania po zapewnieniu implementacji wtyczek metatagów). Jako parsowanie ogólnie nie należy do łatwych zadań (nawet w przypadku tak niewielkiej liczby tokenów), do interpretacji poprawności kolejności tokenów została użyta specjalna maszyna stanów. Programista deklaruje jedynie poprawne i końcowe stany które maszyna może przyjąć, możliwe przejścia między stanami oraz funkcje które powinny być wywołane przy wejściu/opuszczeniu stanu. Po przekazaniu listy tokenów do maszyny stanów, wywołuje ona odpowiednie metody (sprecyzowane wcześniej przez programistę) które budują drzewo wywołań możliwe do zamknięcia w obiekt metawyrażenia. W przypadku błędu (nie poprawnej sekwencji tokenów bądź zakończeniu listy w stanie niekońcowym) maszyna wyrzuca wyjątek z tokenem który powoduje problem.

Klasy tokenizera, leksera, parsera oraz maszyny stanów zostały zaprojektowane do operacji na iteratorach — takie rozwiązanie pozwala skupić się na aktywnym stanie procesu parsowania, a także dzięki separacji etapów procesu umożliwia ponowne wykorzystanie tych modułów.

Drzewo wywołań składa się jedynie z metatagów. Aby otrzymać taką strukturę, ciągi surowego tekstu (nie będące metatagami) zostają zamienione na wywołania anonimowych (nienazwanych) metatagów, których argumentami inicjalizującymi są właśnie surowe ciągi tekstu, a jedyną funkcją — zwrócenie argumentów z listy inicjalizującej. Dzięki temu ewaluacja wyrażeń jest prostsza, a dodatkowy anonimowy metatag może zostać wykorzystany na przykład do zmiany kodowania.



Rysunek 5.5: Drzewo wywołań stworzone z przykładowego metawyrażenia

Rysunek 5.5 ukazuje strukturę drzewa zbudowanego z przykładowego wyrażenia z rysunku 5.4. Widoczna tu jest wygenerowana hierarchia, na której szczycie znajduje się anonimowy tag. Pojedynczy korzeń ułatwia parsowanie i wpasowuje się w logiczną strukturę wyrażenia które nawet nie zagnieżdżone może składać się z kilku następujących po sobie elementów.

Przy ewaluacji drzewo wywołań przeszukiwane jest w głąb (co zostało zaznaczone żółtą przerywaną linią), a jego elementy są ewaluowane od lewej do prawej przy czym metawyrażenia zagnieżdżone w zakresach operacyjnych (zawierających się między klamrami '{' i '}') innych wyrażeń są ewaluowane przed otaczającym je metatagiem-rodzicem. Kolejność ewaluacji jest widoczna na rysunku 5.5 i oznaczona czerwoną, przerywaną linią. W ten sposób rezultat wykonania pod-wyrażenia jest dostępny dla tagu-rodzica, co pozwala na wiązanie wywołań niespotykane w żadnym istniejącym programie tego typu.

Każdy obiekt metatagu musi być zgodny z interfejsem klasy MetatagBase, która zawiera następujące metody wymagające implementacji:

#### 1. void initialize(const UnicodeString &arguments)

#### 2. UnicodeString execute(const UnicodeString &area\_of\_effect)

Pierwsza z metod zostaje wywołana na obiekcie podczas łączenia drzewa wywołań z listą fabryk metatagów i pobiera jako parametr łańcuch znaków będący zawartością nawiasów tuż po nazwie metatagu. Proces tego typu nazywany jest często bindowaniem (od ang. bind).

Metoda execute wywoływana jest za każdym razem podczas ewaluacji wyrażenia dla danego pliku. Jej argumentem jest zakres operacyjny (opcjonalne pod-wyrażenie zawarte w nawiasach klamrowych za listą argumentów).

Obie metody mogą wyrzucać wyjątki informując o niepoprawnym argumencie lub błędzie ekstrakcji metadanych.

## 5.6 System modułów

Aby ułatwić proces projektowania a także zwiększyć rozszerzalność aplikacji, duża część funkcjonalności została oddelegowana do oddzielnych modułów zwanych również wtyczkami. Wtyczki są klasami ładowanymi w trakcie działania programu z bibliotek dynamicznych. W celu udostępnienia aplikacji funkcjonalności zawartych w modułach wtyczek, niezbędne było zaprojektowanie menadżera wtyczek — szablonu DynamicPluginManager. Klasy menadżera wtyczek umożliwiają programiście-użytkownikowi ładowanie modułów z wcześniej zadeklarowanym interfejsem niezależnie od platformy systemowej na której uruchamiany jest program².

Problemem który rozwiązuje menadżer wtyczek jest fakt że biblioteki dynamiczne sprawdzają się najlepiej do przechowywania kodu; klasy które istnieją jedynie na etapie kompilacji nie mogą zostać wyeksportowane do pliku jak ma to miejsce w językach wspierających introspekcje/refleksje typów — takich jak Java czy C#. Aby umożliwić ładowanie wtyczek w języku C++ należy najpierw zdefiniować czym właściwie jest sama wtyczka.

W MRU (jak i wielu innych programach) wtyczka jest obiektem udostępniającym metody określone przez interfejs wtyczki. Także biblioteka dynamiczna musi w jakiś sposób udostępnić owe obiekty.

Menadżer wtyczek po załadowaniu biblioteki dynamicznej przeszukuje ją w poszukiwaniu (zdefiniowanej na poziomie interfejsu wtyczki) funkcji służącej do rejestracji wtyczek. Gdy takową znajdzie, jest ona wywoływana (w kontekście biblioteki dynamicznej) w celu rejestracji fabryk które będą tworzyć instancje wyeksportowanych wtyczek. Fabryki są potrzebne z dwóch powodów: pierwszym z nich jest fakt że nie zawsze istnieje potrzeba tworzenia wtyczki — aplikacja może ładować wiele fabryk wtyczek metatagów ale nie wszystkie z nich będą wykorzystywane w wyrażeniu. Zmniejsza to obciążenie pamięciowe programu jak i ułatwia pracę twórcom wtyczek, którzy mogą skupić się

<sup>&</sup>lt;sup>2</sup>Same moduły muszą być skompilowane pod platformę na której program ma być uruchamiany.

na implementowaniu faktycznej funkcjonalności modułów. Takie rozwiązanie pozwala również programowi-hostowi na decydowanie w jakiej ilości i kiedy mają być tworzone wybrane obiekty. Drugim powodem jest problem występujący przy alokacji pamięci między modułami — aplikacja (host) i moduł biblioteki dynamicznej mogą posiadać osobne sterty, przez co nie istnieje możliwość stworzenia wtyczki w bibliotece, a zwolnieje jej w aplikacji hoście. Dlatego też fabryki w MRU są odpowiedzialne również za de-alokacje pamięci.

## 5.7 Typy modułów w MRU


Aplikacja obsługuje cztery interfejsy wtyczek:

- UiPlugin moduły interfejsu pozwalają na implementacje różnych interfejsów użytkownika.
- InputPlugin moduły wejścia dostarczają programowi ścieżek do wybranych plików.
- OutputPlugin sterowniki wyjścia odpowiadają za faktyczną zmianę identyfikatorów i tworzenie struktury katalogów w systemie plików.
- MetatagPlugin moduły metatagów używanych w wyrażeniach.

## 5.8 Moduły UI

Wtyczki interfejsu użytkownika pozwalają użytkownikowi końcowemu na interakcję z programem. Pojedynczy proces aplikacji może posiadać aktywny tylko jeden moduł UI. Wtyczki interfejsu odpowiadają za całkowitą komunikację między użytkownikiem i rdzeniem aplikacji (MruCore). One także udostępniają większość funkcjonalności narzędzia, a także informują użytkownika o jego stanie i postępie działań.

Jako że funkcjonalność aplikacji jest w dużej mierze determinowana przez klasę rdzenia (MruCore), interfejs UiPlugin nie posiada z góry zdefiniowanych metod jak inne wtyczki.



Rysunek 5.6: Okno aplikacji MRU — wtyczka wxWidgetsUi

Jedyna metoda w nim zawarta — start — pozwala na reinterpretacje linii poleceń i służy do przekazania kontroli nad programem właśnie do samej wtyczki.

#### 5.8.1 wxWidgetsUi

wxWidgetsUi jest implementacją graficznego interfejsu użytkownika opartego na wspomnianej bibliotece wxWidgets. Założeniem tego modułu jest udostępnienie użytkownikowi końcowemu prostego oraz szybkiego dostępu do funkcjonalności programu, a także pomoc w zapoznaniu się z aplikacją.

Okno aplikacji stworzone przez wtyczkę wxWidgetsUi jest podzielone na trzy sekcje:

 Sekcja górna odpowiada za selekcję plików oraz pozwala na edycję metawyrażenia które ma zostać zastosowane na wybranych plikach. W lewym górnym rogu widnieje lista dostępnych Metatagów, a pola po prawej stronie pozwalają na wybór katalogu, filtru glob oraz samego metawyrażenia.

- Środkowa część okna stanowi podgląd wybranych plików jak i efektów zastosowania edytowanego wyrażenia do nich. Lista plików może być ograniczona i odświeżana w zależności od opcji znajdujących się pod nią.
- Na dole okna widoczne są przyciski do (ręcznego) generowania podglądu, jego konfiguracji, a także rozpoczęcia transformacji nazw dla wybranych plików.

## 5.9 InputPlugin

Jako że biblioteka standardowa języka C++ nie udostępnia mechanizmów pozwalających na iteracje po katalogach, aplikacja musi korzystać z dodatkowych bibliotek lub API systemu operacyjnego. W celu izolacji kodu zależnego od platformy i zmniejszenia zależności rdzenia aplikacji, MRU korzysta z wtyczek wejścia — InputPlugin — odpowiedzialnych za iteracje po wybranym przez użytkownika katalogu.

Interfejs wtyczki wejścia pozwala aplikacji na jej prostą konfiguracje (wybór typów plików do iteracji i poziomu przeszukiwania), a także udostępnia iterator — FileIterator — generujący kolejne ścieżki do wybranych plików.

#### 5.9.1 Dekoratory iteratora

W przypadku użycia 'surowego' iteratora plików<sup>3</sup> problemem okazała się kolejność generowanych ścieżek oraz typy plików przez nie wskazywanych. O ile iterator faktycznie generował poprawne ścieżki, to ich kolejność nie odpowiadała choćby leksykalnej kolejności plików w katalogu. Istnieje wiele sytuacji w których pozycja pliku nie wpływa na generowanie identyfikatora, jednak metatagi takie jak?? biorą ją pod uwagę. Oczywistym rozwiązaniem zdaje się być sortowanie wejściowej listy ścieżek lecz w przypadku dużych kolekcji może to stanowić zbyt duży narzut czasowo-pamięciowy i jak wcześniej zostało wspomniane — nie zawsze zachodzi potrzeba sortowania. Aby umożliwić użytkownikowi

<sup>&</sup>lt;sup>3</sup>Problem występował przynajmniej przy użyciu wtyczki BoostInput opartej na module boost::filesystem

sortowanie wejściowej listy plików zastosowano dekorator SortingFileIterator, który można podłączyć lub odłączyć w zależności od wyboru użytkownika.

Kolejnym problemem było zwracanie przez iterator praktycznie wszystkich plików znajdujących się w wybranym katalogu. Użytkownik aplikacji powinien mieć możliwość określenia które pliki mają podlegać zmianie.

Dzięki wykorzystaniu dekoratora filtrującego FilteringFileIterator aplikacja może wykorzystać dowolny predykat do dynamicznego sprawdzenia czy plik powinien znaleźć się na liście wejściowej.

## 5.10 Moduł OutputPlugin — BoostOutput

Aby wygenerowane identyfikatory mogły zastąpić już istniejące w w systemie plików, powstał interfejs wtyczki OutputPlugin. Jego zadaniem jest udostępnienie aplikacji podstawowych operacji na plikach: kopiowania, przenoszenia, tworzenia i usuwania katalogów. Istotne jest że wtyczka wyjścia wcale nie musi ingerować w strukturę drzewa plików — stosując wtyczkę zapisującą informacje do pliku tekstowego, możliwe jest wygenerowanie raportu zawierającego metadane wybranych plików.

## 5.11 Moduły metatagów

Główna funkcjonalność aplikacji została zawarta w modułach tagów — to one odpowiadają za ekstrakcje metadanych lub generowanie wartości, które rdzeń aplikacji jedynie składa i przesyła wraz z komunikatem zmiany do modułu wyjścia.

Każdy z poniżej wymienionych tagów może zostać dodany do wyrażenia po załadowaniu odpowiedniej biblioteki dynamicznej go zawierającej

#### 5.11.1 Count

Metatag Count jest używany do numeracji wybranych plików. Dla każdego pliku generowany jest kolejny numer. Lista argumentów tagu pozwala na określenie wartości

początkowej oraz kroku iteracji. W poniższej tabeli zawarte zostały parametry obsługiwane przez metatag:

Argument	Opis
start=N	Ustawia początkowy stan licznika na $N$ — od tej wartości tag rozpocznie
	zliczanie
step=K	Ustawia rozmiar kroku — kolejny numer będzie większy o $K$ w stosunku
	do poprzedniego

Tablica 5.1: Zestaw argumentów inicjalizacyjnych dla metatagu Count

Aby wykorzystać kilka argumentów jednocześnie należy oddzielić je od siebie za pomocą symbolu przecinka — ', '.

#### 5.11.2 Audio

Metatag Audio został oparty na bibliotece TagLib i pozwala na ekstrakcję metadanych z wielu plików multimedialnych. Tag ten obsługuje następujące argumenty:

Argument	Opis
title	Ekstrakcja tytułu utworu
artist	Ekstrakcja nazwy artysty wykonującego utwór
album	Ekstrakcja nazwy albumu w którym zawiera się utwór
year	Ekstrakcja roku powstania utworu
comment	Ekstrakcja komentarza

Tablica 5.2: Zestaw argumentów inicjalizacyjnych dla metatagu Audio

#### 5.11.3 Name

Metatag Name reprezentuje źródłową nazwę pliku bez rozszerzenia oraz katalogu zawierającego. Może być używany gdy zachodzi potrzeba dodania prefiksu lub sufiksu do istniejącej nazwy pliku. Dzięki składni metawyrażeń możliwa jest również modyfikacja źródłowego identyfikatora na przykład za pomocą tagu TextCase.

#### 5.11.4 Ext

Metatag Ext reprezentuje rozszerzenie pliku. Jako że modyfikacja rozszerzenia może prowadzić to błędnej interpretacji pliku przez inne programy, często jest niepożądana. Metatag Ext użyty na końcu metawyrażenia stosowany jest w celu zachowania rozszerzenia pliku.

#### 5.11.5 Dir

Dir jest metatagiem reprezentującym ścieżkę w której znajduje się przetwarzany plik. Ścieżka zwracana przez Dir jest ścieżką pośrednią w stosunku do katalogu przetwarzania wybranego przez użytkownika — dla plików znajdujących się bezpośrednio w wybranym katalogu, metatag Dir zwraca pusty tekst.

#### 5.11.6 TextCase

Metatag TextCase jest używany do zmiany wielkości liter w skojarzonym z tagiem zakresie działania. Pewność działania dla pełnego zakresu kodów unicode jest zapewniona dzięki wykorzystaniu funkcji z biblioteki ICU.

Argument	Opis
upper	Wszystkie znaki w zakresie zostaną zamienione na ich większe odpowied-
	niki
lower	Wszystkie znaki w zakresie zostaną zamienione na ich mniejsze odpo-
	wiedniki
title	Wszystkie znaki w zakresie zostaną zamienione tak by wyglądały na tytuł
	(Pierwsze znaki każdego słowa są zamieniane na ich większe odpowiedniki

Tablica 5.3: Zestaw argumentów inicjalizacyjnych dla metatagu TextCase

## **5.12** Testy

W celu przetestowania aplikacji ze strony http://www.jamendo.com/pl/track/986557/pulsar zostało pobrane archiwum zawierające album muzyczny z plikami w formacie MPEG-1/MPEG-2 Audio Layer 3 — popularnie zwanym 'MP3' — które to zawierają poprawnie sformatowane tagi ID3 w wersji 2.4.0.

Celem testu było sprawdzenia parsera metawyrażeń, filtra regex, a także ogólnego działania programu. Na rysunku 5.7 widać stan katalogu przed uruchomieniem programu.

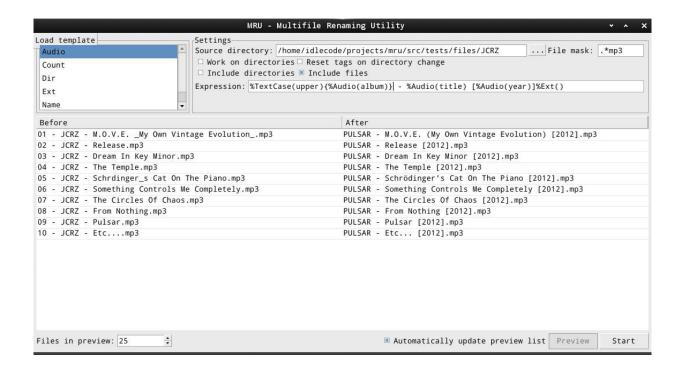
```
[10:04:52][/home/idlecode/projects/mru/src/tests/files/JCRZ]
[idlecode]> ls
01 - JCRZ - M.O.V.E. _My Own Vintage Evolution_.mp3
02 - JCRZ - Release.mp3
03 - JCRZ - Dream In Key Minor.mp3
04 - JCRZ - The Temple.mp3
05 - JCRZ - Schrdinger_s Cat On The Piano.mp3
06 - JCRZ - Something Controls Me Completely.mp3
07 - JCRZ - The Circles Of Chaos.mp3
08 - JCRZ - From Nothing.mp3
09 - JCRZ - Pulsar.mp3
10 - JCRZ - Etc....mp3
Cover.jpg
License.txt
[10:04:55][/home/idlecode/projects/mru/src/tests/files/JCRZ]
[idlecode]>
```

Rysunek 5.7: Stan plików przed zmianą

Do testów zostało wybrane metawyrażenie wykorzystujące metatagi Audio, TextCase oraz Ext. Celem użytego metawyrażenia jest kompozycja nazwy składającej się z nazwy albumu do którego utwór należy (metatag %Audio(album)) pisanej dużymi literami, po której następuje tytuł (%Audio(title)) oraz rok wydania utworu w nawiasach kwadratowych ([%Audio(year)]). Wykorzystany na końcu metatag Ext, zapewnia że pliki wynikowe będą posiadały takie samo rozszerzenia jak w nazwa źródłowa.

Dodatkowo w celu zmniejszenia ilości błędów został zastosowany filtr z wyrażeniem regularnym ".\*mp3", który zapewnia że program będzie przetwarzać jedynie pliki zakończone ciągiem znaków "mp3".

%TextCase(upper){%Audio(album)} - %Audio(title) [%Audio(year)]%Ext()



Rysunek 5.8: Konfiguracja aplikacji użyta do zmiany identyfikatorów

# 5.13 Możliwości rozwoju i ponownego wykorzystania komponentów

Dzięki zastosowanej architekturze modułowej, części aplikacji nie posiadają dużych zależności między-modułowych co stwarza idealne warunki do ich rozwoju i ponownego użycia istniejącego kodu (na przykład wtyczek) w innych projektach.

System wtyczek został zaimplementowany w formie biblioteki niezależnej od platformy i nie posiadającej rozwiązań specyficznych dla aplikacji w której został wykorzystany.

```
urxvt
[10:04:55][/home/idlecode/projects/mru/src/tests/files/JCRZ]
[idlecode]> ls
Cover.jpg
License.txt
PULSAR - Dream In Key Minor [2012].mp3
PULSAR - Etc... [2012].mp3
PULSAR - From Nothing [2012].mp3
PULSAR - M.O.V.E. (My Own Vintage Evolution) [2012].mp3
PULSAR - Pulsar [2012].mp3
PULSAR - Release [2012].mp3
PULSAR - Schrödinger's Cat On The Piano [2012].mp3
PULSAR - Something Controls Me Completely [2012].mp3
PULSAR - The Circles Of Chaos [2012].mp3
PULSAR - The Temple [2012].mp3
[10:06:20][/home/idlecode/projects/mru/src/tests/files/JCRZ]
[idlecode]>
```

Rysunek 5.9: Stan plików po zmianie

Dzięki temu jego wykorzystanie w innych projektach nie wymaga dodatkowego narzutu związanego z modyfikacją kodu.

Moduły metatagów wymagają jedynie dostępu do pliku na którym mają operować i same nie są świadome metawyrażeń w których występują. Dzięki zastosowanie takiej izolacji, dodawanie nowych wtyczek nie wywiera wpływu na działający program, a istniejące metatagi mogą zostać wykorzystane z powodzeniem w innych aplikacjach, które wymagają dostępu do metadanych. Dzięki spójnemu interfejsowi, metatagi mogą stanowić alternatywę dla wykorzystywania dedykowanych bibliotek do obsługi formatów plików, które często zawierają sporo narzutu związanego z funkcjami bezpośrednio nie związanymi z danymi — jak na przykład zapisem faktycznych danych.

Metatagi (szczególnie generujące sumy kontrolne) mogą znaleźć również zastosowanie przy porównywaniu plików w celu identyfikacji duplikatów.

Wtyczki wyjścia — OutputPlugin — nie mają w żaden sposób narzuconej implementacji. Nic więc nie stoi na przeszkodzie aby stworzyć wtyczkę która generuje na przykład tekstowe raporty dla istniejących plików zawierające metadane w nich zawarte.

## Rozdział 6.

## Wnioski

Wiele bibliotek i szczegółów implementacji sprawiło że projekt pracy inżynierskiej okazał się nieco trudniejszy niż było to przewidywane. Dużą częścią pracy stanowiło połączenie istniejących bibliotek i technologii aby mogły ze sobą współpracować. Różnica zaawansowania oraz stylów interfejsów użytych narzędzi wymusiła tworzenie dodatkowych abstrakcji lecz dzięki temu, pozwoliła także na zmniejszenie zależności między-modułowych co zaowocowało powstaniem aplikacji o dużych możliwościach rozwoju.

Również projekt architektury aplikacji okazał się nie tak prosty jak mogłoby to wynikać z założeń. Aby móc stosować operacje działające na wielkich zbiorach danych, przepisany musiał zostać cały system wtyczek wejścia, który w pierwszej po prostu wczytywał listę plików, a w ostatecznej był kaskadą iteratorów.

Nad wyraz ciekawym doświadczeniem okazał się również parser metawyrażeń. W pierwszej wersji został on zaimplementowany w sposób spójny i monolityczny, jednak gdy zaszła potrzeba jego rozszerzenia, musiał zostać podzielony na bardziej niezależne moduły (tokenizera, leksera i samego parsera). Zaowocowało to ciekawą architekturą, którą autor planuje rozwijać w przyszłości.

Stworzona aplikacja sprostała założeniom pod które została zaprojektowana i stanowi dzięki temu użyteczne narzędzie które może pozwolić ludziom na to na co zostały

stworzone komputery — zautomatyzowanie monotonnych czynności i przyspieszenie pracy.

Dodatkową zaletą wykonanej aplikacji jest fakt że niektóre jej części (takie jak menadżer wtyczek) dzięki swojej uniwersalności mogą posłużyć do budowy kolejnych programów.

# Spis rysunków

3.1	Okno główne programu Bulk Rename Utility	17
3.2	Jedna z zakładek programu Métamorphose	18
3.3	Konfiguracja szablonu nazwy pliku w KRename	19
4.1	Logo systemu Mercurial	22
4.2	Logo narzędzia CMake	23
4.3	Logo edytora Vim	23
5.1	Logo biblioteki SigC++	25
5.2	Logo biblioteki wxWidgets	26
5.3	Metatag z wyróżnionymi elemetami na niego się składającymi	29
5.4	Przykładowe metawyrażenie wraz z wyróżnionymi elementami metatagów .	29
5.5	Drzewo wywołań stworzone z przykładowego metawyrażenia	31
5.6	Okno aplikacji MRU — wtyczka wxWidgetsUi	35
5.7	Stan plików przed zmianą	40
5.8	Konfiguracja aplikacji użyta do zmiany identyfikatorów	41
5.9	Stan plików po zmianie	42

# Spis tablic

5.1	Zestaw argumentów inicjalizacyjnych dla metatagu Count	38
5.2	Zestaw argumentów inicjalizacyjnych dla metatagu Audio	38
5.3	Zestaw argumentów inicjalizacyjnych dla metatagu TextCase	39

## Bibliografia

- [1] Chuck Allison Bruce Eckel. Thinking in C++ Tom 2. Wydawnictwo Helion, 2004.
- [2] William Stallings. Organizacja i architektura systemu komputerowego. Wydawnictwo WNT, 2004.
- [3] Eric Sink. Version Control by Example. Pyrenean Gold Press, 2011.
- [4] Björn Karlsson. Więcej niż C++: Wprowadzenie do bibliotek Boost. Wydawnictwo Helion, 2006.
- [5] David A. Wheeler. Fixing unix/linux/posix filenames: Control characters (such as newline), leading dashes, and other problems. http://www.dwheeler.com/essays/fixing-unix-linux-filenames.html, March 2009. [dostęp: 2013-07-02].
- [6] Wikipedia. Path (computing) wikipedia, the free encyclopedia. http://en.wikipedia.org/w/index.php?title=Path\_(computing)&oldid=560778566, 2013. [dostep: 2013-07-02].
- [7] Martin Hinner. Filesystems howto. http://www.tldp.org/HOWTO/Filesystems-HOWTO.html, Styczeń 2007. [dostęp: 2013-07-02].
- [8] The IEEE and The Open Group. The open group base specifications issue 6 ieee std 1003.1, 2004 edition. http://pubs.opengroup.org/onlinepubs/009695399/, 2004. [dostep: 2013-07-02].